

## 1 Strace

# 1.1. strace 相关基础知识

## 1.1.1. 什么是 strace

strace 是一个很有用的诊断、学习、调试工具。使用时无需重新编译程序,这也使得可以用来跟踪没有源代码的程序。系统调用和信号是发生在用户空间边界处的事件,检查这些边界事件有助于隔离错误、检查完整性、跟踪程序。

使用 strace 工具来执行程序时,它会纪录程序执行过程中调用的系统调用、接收到的信号。通过查看记录结果,可以知道程序打开了那些文件(open)、打开是否成功、对文件进行了那些读写操作(read、write、ioctl 等)映射了那些内存(mmp)、向系统申请了多少内存等。

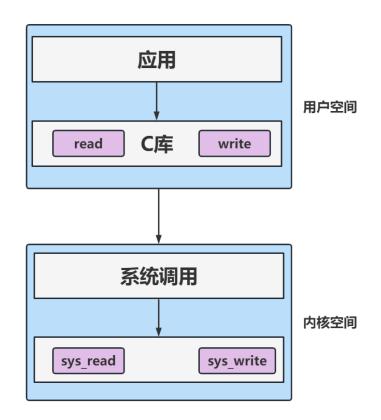
## 1.1.2. 为什么要学会 strace

我们知道,对于应用开发者而言,应用程序的边界是系统调用,进入到系统调用中就是Linux内核了。所以,要想拓展分析问题的边界,你首先需要知道该怎么去分析应用程序使用的系统调用函数。对于内核开发者而言,边界同样是系统调用,系统调用之外是应用程序。如果内核开发者想要拓展分析问题的边界,也需要知道如何利用系统调用去追踪应用程序的逻辑。

#### 1.1.3. 什么是系统调用

系统调用是应用程序在执行过程中向操作系统内核申请服务的方法,这可能包含硬件相关的服务、新进程的创建和执行以及进程调度。





## 1.2. strace 的使用

直接运行 strace -h, 查看到它的用法:

### 1.2.1. strace 相关参数

下面是几个常用的选项:

- □ -f: 除了跟踪当前进程外,还跟踪其子进程。
- □ -o file:将输出信息写到文件 file 中,而不是显示到标准错误输出(stderr)。
- □ -p pid: 绑定到一个由 pid 对应的正在运行的进程。此参数常用调试后台进程。
- □ -t: 打印各个系统调用被调用是的绝对时间,想观察程序各个部分的执行时间可以使用这个选项。
  - □ -tt: 与-t 选项相似, 打印的时间精度为 μ s。
  - □ -r;与选项-t 相似,打印的时间为相对时间。



## 1.2.2. strace 简单案例

使用 strace 的最简单例子:

在 strace 的输出结果中,每一行对应一个系统调用;首先是系统调用的名字,紧接着是被包含在括号中的参数,最后是它的返回值,

如第 1 行所示,表示通过系统调用 execve 来建立一个进程,它就是 "cat /dev/dull" 对应的进程。在控制台中执行各种命令,比如 "ls", "cd"时,都通过系统调用 execve 来建立它们的进程的。最后返回值为 0,表示执行成功。

上面例子中,我们忽略中间的打印,看下最后的输出,如上图所示首先打开 "/dev/null" 文件,这个才是我们"cat/dev/null"命令的真正处理过程,然后读取它的内容。

## 1.2.3. 使用 strace 来测量程序的执行时间

当我们如果发现某个程序突然执行的很慢,通常需要找出其中哪部分代码执行时间过长,使用 strace 工具可以轻易达到这个目的。

```
strace - r sleep 2
0.000685 nanosleep({tv_sec=2, tv_nsec=0}, 0x7ec97c10) = 0
2.001112 exit_group(0) = ?
0.001677 +++ exited with 0 +++_
```

如上图实验截图可见, 打印了出 sleep 的执行时间。

### 1.2.4. 使用 strace 来测量程序的执行时间

```
[root@imsGull:-]# strace -tt -T -e traces-scket.bind, connect ping -c 1 baidu.com
00:02:06.11448 socket.lAF_UNIX, SOCK_STREAN|SOCK_CLOEXEC|SOCK_NOMBLOCK.0] = 3 <0.000313>
00:02:06.116187 connect(3, 4sa_family=AF_UNIX, SOCK_STREAN|SOCK_CLOEXEC|SOCK_NOMBLOCK.0] = 3 <0.000313>
00:02:06.116187 connect(3, 4sa_family=AF_UNIX, SOCK_STREAN|SOCK_CLOEXEC|SOCK_NOMBLOCK.0] = 3 <0.000313>
00:02:06.117034 connect(3), 4sa_family=AF_UNIX, SOCK_STREAN|SOCK_CLOEXEC|SOCK_NOMBLOCK.0] = 3 <0.000316>
00:02:06.117034 connect(3), 4sa_family=AF_UNIX, sun_path=-/var/run/nscd/socket/).110] = -1 ENDENT (No such file or directory) <0.000359>
00:02:06.127937 connect(3), 4sa_family=AF_INET6, SING_port=htons(93), inet_pton(AF_INET6, "::1", 6sin6_addr), sin6_flowinfo=htonl(0), sin6_scope_id=0}, 28) = 0 <0.000146>
00:02:10.133076 socket(AF_INET, SOCK_DORAM|SOCK_NOMBLOCK, IPPROTO_IP) = 4 <0.000275>
00:02:11.134088 connect(4, {sa_family=AF_INET, sin_port=htons(53), sin_addr=inet_addr("127.0.0.1")}, 16) = 0 <0.000276>
```

加上-T 选项后,每行系统调用信息的最右侧会标识出该系统调用的耗时,如<0.000146>。



## 1.2.5. 统计每个系统调动的耗时、调用次数、失败数

## 1.2.6. 跟踪所有网络相关的系统调用

```
[root@imxGull:-]# strace -e trace=%network ping -c 1 baidu.com socket(AF_UNIX, SOCK_STREAM)SOCK_CLOEXE(SOCK_NONBLOCK, 0) = 3 connect(3, {sa_family=AF_UNIX, sock_STREAM)SOCK_CLOEXE(SOCK_NONBLOCK, 0) = 3 connect(3, {sa_family=AF_UNIX, sock_STREAM)SOCK_CLOEXE(SOCK_NONBLOCK, 0) = 3 connect(3, {sa_family=AF_UNIX, sock_STREAM)SOCK_STREAM)SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STREAM)SOCK_STREAM(SOCK_STR
```

-e trace=%network 或者-e trace=%net 是跟踪网络相关系统调用的选项。实际输出的内容远比这个多,这是做了适当省略后的输出。

#### 1.2.7. 跟踪所有信号相关的系统调用

```
[root@imx6ull:-]# strace -e trace=%signal sh -c echo voidint
rt_sigprocmask(SIG_BLOCK, NULL, [], 8) = 0
rt_sigaction(SIGCHLD, (sa_handler=SIG_DFL, sa_mask=[], sa_flags=SA_RESTORER|SA_RESTART, sa_restorer=0x76de7101}, (sa_handler=SIG_DFL, sa_mask=[], sa_flags=SA_RESTORER|SA_RESTART, sa_restorer=0x76de7101}, (sa_handler=SIG_DFL, sa_mask=[], sa_flags=SA_RESTORER|SA_RESTART, sa_restorer=0x76de7101}, (sa_handler=SIG_DFL, sa_mask=[], sa_flags=SA_RESTORER, sa_restorer=0x76de7101}, (sa_handler=SIG_DFL, sa_mask=[], sa_flags=
```



## 1.2.8. 跟踪含有文件名参数的系统调用

```
[root@imx6ull:~]# strace -e trace=%file ls /
clone(child_stack=NULL, flags=cLONE_CHILD_CLEATID|CLONE_CHILD_SETTID|SIGCHLD, child_tidptr=0x76fa8068) = 345
wait4(-1, execve("hin/ls", "is", "/"], 0x7e95adbc /* 15 vars */) = 0
access("/etc/ld.so.preload", R_OK) = -1 ENDENT (No such file or directory)
open("/etc/ld.so.cache", O_RDONLY|O_CLOEXEC) = 1 ENDENT (No such file or directory)
open("/lib/tls/vTl/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/vTl/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/vTl/neon/libresolv.so.2", O_RDONLY|O_CLOEXEC) = -1 ENDENT (No such file or directory)
open("/lib/tls/vTl/neon", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/vTl/nfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/vTl/nfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/mon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tl/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or directory)
open("/lib/tls/neon/vfp", 0x7ee7c6e8) = -1 ENDENT (No such file or direc
```

```
open("/tib/tibresolv.so.2", O_ROUNLY|O_CLOEXEC) = 1 ENDENT (No such file or directory)

open("/lib/libresolv.so.2", O_RDONLY|O_CLOEXEC) = 3

open("/lib/libc.so.6", O_ROUNLY|O_CLOEXEC) = 3

open("/lib/libc.so.6", O_ROUNLY|O_CLOEXEC) = 3

stat64("/, (st_mode=S_IFDIR(0755), st_size=1024, ...}) = 0

open("/", O_ROUNLY|O_NONBLOCK|O_LARGEFILE|O_CLOEXEC|O_DIRECTORY) = 3

lstat64("/lib", (st_mode=S_IFDIR(0755), st_size=2048, ...}) = 0

lstat64("/depin-boot-maker.exe.2", (st_mode=S_IFREG|0644, st_size=16722432, ...}) = 0

lstat64("/depin-boot-maker.exe.2", (st_mode=S_IFREG|0644, st_size=16722432, ...}) = 0

lstat64("/depin-boot-maker.exe.2", (st_mode=S_IFREG|0644, st_size=1024, ...}) = 0

lstat64("/wisr", (st_mode=S_IFDIR(0755), st_size=304, ...}) = 0

lstat64("/bin", (st_mode=S_IFDIR(0755), st_size=304, ...}) = 0

lstat64("/bin", (st_mode=S_IFDIR(0755), st_size=304, ...}) = 0

lstat64("/bin", (st_mode=S_IFDIR(0755), st_size=304, ...}) = 0

lstat64("/mirrors.php", (st_mode=S_IFREG|0644, st_size=1024, ...}) = 0

lstat64("/mirrors.php", (st_mode=S_IFREG)0644, st_size=1024, ...}) = 0

lstat64("/sbin", (st_mode=S_IFDIR(0755), st_size=1024, ...}) = 0

lstat64("/depin-boot-maker.exe.1", (st_mode=S_IREG)0644, st_size=121881, ...)) = 0

lstat64("/devin-boot-maker.exe.3", (st_mode=S_IREG)0644, st_size=16722432, ...)) = 0

lstat64("/devin-boot-maker.exe.3", (st_mode=S_IREG)0644, st_size=16722432, ...)) = 0

lstat64("/devin-boot-maker.exe.3", (st_mode=S_IREG)0644, st_size=16722432, ...)) = 0

lstat64("/inuxrc', (st_mode=S_IFDIR(0755), st_size=340, ...)) = 0

lstat64("/inuxrc', (st_mode=S_IFDIR(0755), st_size=1024, ...)) = 0

lstat64(
```

仔细观察上面的示例可以发现,指定-e trace=%file 选项后,输出的内容拥有一个共同的特点,即均是包含文件名参数的系统调用。



## 1.2.9. 跟踪已运行进程

此处以进程 ntpd 为例,尝试去跟踪该进程的系统调用。一般线上问题排查场景也是附 加到一个正在运行的进程上,观察该进程的系统调用,看是否有错误发生,看是否某个系统 调用执行时间过长等。

除了可以指定进程名,我们还可以指定对应进程号。

我们可以先通过 ps 命令查看:

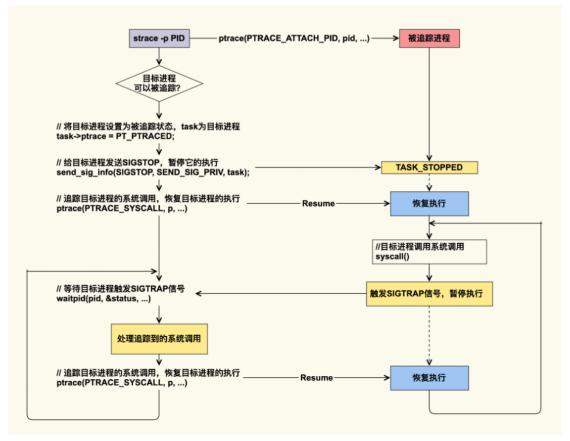
```
root /usr/sbin/ntpd -g
root nginx: master process /usr/sbin/nginx
swww-data nginx: worker process
root /usr/sbin/sshd
root smbd -D
root {smbd-notifyd} smbd -D
root {cleanupd} smbd -D
root {lpqd} smbd -D
root nmbd -D
root -sh
303 www-d
306 root
318 root
321 root
322 root
323 root
324 root
                                                            -sh
```

可以知道, ntpd 对应的进程号为 290。

## 1.3. strace 的工作原理

strace 工具的原理如下图所示:





我们从图中可以看到,对于正在运行的进程而言,strace 可以 attach 到目标进程上,这是通过 ptrace 这个系统调用实现的(gdb 工具也是如此)。ptrace 的 PTRACE\_SYSCALL 会去追踪目标进程的系统调用;目标进程被追踪后,每次进入 syscall,都会产生 SIGTRAP 信号并暂停执行;追踪者通过目标进程触发的 SIGTRAP 信号,就可以知道目标进程进入了系统调用,然后追踪者会去处理该系统调用,我们用 strace 命令观察到的信息输出就是该处理的结果;追踪者处理完该系统调用后,就会恢复目标进程的执行。被恢复的目标进程会一直执行下去,直到下一个系统调用。

你可以发现,目标进程每执行一次系统调用都会被打断,等 strace 处理完后,目标进程才能继续执行,这就会给目标进程带来比较明显的延迟。因此,在生产环境中我不建议使用该命令,如果你要使用该命令来追踪生产环境的问题,那就一定要做好预案。

假设我们使用 strace 跟踪到,线程延迟抖动是由某一个系统调用耗时长导致的,那么接下来我们该怎么继续追踪呢?这就到了应用开发者和运维人员需要拓展分析边界的时刻了,对内核开发者来说,这才算是分析问题的开始。